

1 引言

基于位置的社交网络 (location-based social networks, LBSNs) 如 Foursquare、Yelp 和大众点评等平台的广泛普及, 积累了海量的用户签到数据. 这些数据记录了用户与城市兴趣点 (Point-of-Interest, POI) 之间的交互行为, 为个性化下一跳 POI 推荐服务提供了重要的数据基础 [1, 2]. 与传统的序列推荐 (如电影或商品推荐) 不同, 下一 POI 推荐直接面向城市空间中的实体对象, 既要刻画用户偏好, 又要理解地点之间的转移关系、地理约束和语义功能差异, 因此天然具有时空异构、多模态融合和强上下文依赖的特点.

从数据视角看, 下一 POI 推荐并不是单纯的序列预测任务, 而是一个典型的多模态数据管理与融合问题. 一方面, POI 本身同时具有图结构连通性、地理坐标、类别标签和文本语义等异构属性; 另一方面, 用户轨迹又引入了显式的时间顺序、周期性行为和跨区域迁移模式. 这些模态在粒度、噪声水平、稀疏性和更新频率上均存在显著差异: 例如, 转移拓扑依赖历史行为统计, 文本语义来自相对静态的元数据描述, 空间坐标具有连续度量结构, 而时间模态则反映用户活动节律. 如何在统一框架中实现不同模态的组织、对齐、融合与下游推荐, 是多模态 POI 推荐研究中的关键问题.

早期下一 POI 推荐方法 [3, 4] 主要依赖于循环神经网络或自注意力机制对签到序列进行建模, 并将空间和时间信息作为辅助特征注入. 这类方法推动了时空序列建模的发展, 但通常仍将 POI 压缩为单一嵌入向量, 对地点语义、转移结构和上下文依赖之间的协同关系刻画不足. 近年来, 大语言模型 (large language models, LLMs) [5, 6] 的成功激发了研究者利用预训练语言模型进行轨迹理解. 在路径表示学习领域, 已有工作通过对比学习对齐拓扑和语义模态 [7], 展示了多模态融合在移动性任务中的潜力. 多模态表示学习在视觉-语言理解等跨领域任务中同样取得了显著进展 [8], 为将 POI 文本语义与结构信息联合建模提供了借鉴.

尽管如此, 现有工作在多模态融合方面仍面临三个关键挑战. 首先, POI 的拓扑、语义、空间和时间信息来自不同数据源, 其表示粒度和统计分布差异显著, 直接融合容易造成模态语义错位. 特别是拓扑模态强调用户行为中的转移连通性, 语义模态强调地点功能和类别相似性, 二者虽然互补, 却天然处于不同表示空间. 其次, 用户移动行为具有强上下文依赖, 在通勤、消费、娱乐和跨区域移动等不同场景下, 各模态的重要性会动态变化, 固定权重融合或简单拼接难以适应这种轨迹上下文差异. 再次, 预训练序列模型为轨迹建模提供了强大的自回归建模结构, 但如何将异构 POI 属性组织为适合序列骨干处理的多模态 token, 并在有限签到数据上实现有效适配, 仍需要专门设计.

针对上述问题, 本文提出一种多模态 POI 表示学习框架. 该框架将 POI 建模为四种明确的模态: 拓扑模态 (图结构嵌入与转移图特征)、语义模态 (文本描述与类别嵌入)、空间模态 (GPS 坐标) 和时间模态 (签到时刻与时间间隔). 在此基础上, 本文设计了三项核心机制: (1) SemAlign 跨模态对齐模块, 通过实例级和特征级 InfoNCE 损失将拓扑和语义表示对齐到统一的共享空间, 缓解异构模态表示空间不一致问题; (2) ContextFusion 自适应上下文门控融合机制, 根据序列上下文动态调节拓扑和语义特征的融合权重, 克服固定融合策略对移动场景变化适应性不足的问题; (3) 选择性微调 GPT-2 骨干网络, 仅更新位置嵌入和层归一化参数, 利用预训练自回归序列结构完成多模态 POI token 的序列建模与下一 POI 预测.

与侧重候选空间约束或轨迹语言化推理的工作不同, 本文关注 POI 对象自身的多模态表示组织、跨模态对齐与上下文自适应融合问题. 这些机制与候选生成、重排序和用户协同建模具有互补性: 一方面, 高质量的多模态 POI 表示能够提升全空间匹配和候选重排序的判别能力; 另一方面, 上下文感知的融合权重也为解释不同轨迹场景下的推荐依据提供了可分析信号. 因此, 本文从多模态数据管理与融合视角出发, 系统研究四类 POI 模态如何被统一组织、显式对齐并服务于下一 POI 推荐.

本文的主要贡献如下.

- (1) 提出四种显式模态编码器 (拓扑、语义、空间、时间), 将 POI 的多模态特性系统性地纳入统一的表示学习框架.
- (2) 设计 SemAlign 跨模态对齐模块, 通过实例级和特征级 InfoNCE 损失的双层对齐策略, 实现拓扑与语义

点在物理上可达”，时间模态则强调“在何时何地更可能发生访问行为”。这些模态之间既互补又可能产生冲突：例如，两个语义相似的咖啡馆可能在空间上相距很远，而两个空间相近的 POI 在功能上可能完全不同。因此，如何在保持模态判别性的同时学习跨模态的一致性，并让融合过程对上下文敏感，是本文方法设计的出发点。

3 问题定义

本文研究 LBSN 场景下的下一兴趣点 (Point-of-Interest, POI) 推荐问题。设用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$, POI 集合为 $\mathcal{P} = \{p_1, p_2, \dots, p_M\}$ 。每个 POI $p_j \in \mathcal{P}$ 具有相应的地理位置 $\mathbf{g}_j = (lat_j, lng_j)$ 、类别信息 $c_j \in \mathcal{C}$ ，并可关联名称、描述等文本语义信息。用户 u 在时间 t_i 对 POI p_i 的一次访问行为定义为签到记录：

$$x_i^u = (u, p_i, t_i). \quad (1)$$

对于用户 u ，将其历史签到记录按照时间顺序排列，得到用户历史访问轨迹：

$$\mathcal{H}_u^{(n)} = [x_1^u, x_2^u, \dots, x_n^u], \quad t_1 < t_2 < \dots < t_n, \quad (2)$$

其中， $\mathcal{H}_u^{(n)}$ 表示用户 u 截至当前时刻的历史访问序列。

在多模态 POI 推荐场景中，除历史访问轨迹外，任务还可以利用与用户轨迹和候选 POI 相关的可用上下文信息。本文用 $\mathbf{m}_u^{(n)}$ 表示用户 u 历史轨迹中的多模态上下文，其可包括 POI 地理位置、类别属性、文本语义、签到时间以及由历史访问行为形成的转移关系等信息。这些信息均作为下一 POI 推荐任务的可用输入，用于描述用户访问行为及候选 POI 的上下文属性。

下一 POI 推荐任务旨在根据用户 u 的历史访问轨迹 $\mathcal{H}_u^{(n)}$ 、可用的多模态上下文 $\mathbf{m}_u^{(n)}$ 以及候选 POI 集合 $\mathcal{P}$ ，预测用户在下一时刻最可能访问的 POI p_{n+1} 。任务输出为候选 POI 上的排序结果，并返回 Top- K 推荐列表：

$$\mathcal{R}_u^K = [p_{r_1}, p_{r_2}, \dots, p_{r_K}], \quad p_{r_i} \in \mathcal{P}. \quad (3)$$

该任务的目标是使用户真实访问的下一 POI p_{n+1} 在推荐列表 $\mathcal{R}_u^K$ 中获得尽可能高的排名。

4 模型方法

本文提出的多模态 POI 推荐框架总体架构如图 1 所示。模型包含四个主要阶段：(1) 多模态 POI 编码，(2) 跨模态对齐 (SemAlign)，(3) 自适应上下文融合 (ContextFusion)，以及 (4) 基于选择性微调 GPT-2 的序列建模。每个阶段的详细设计如下。

4.1 多模态 POI 编码

4.1.1 拓扑编码器

拓扑模态捕获 POI 之间的结构关系。我们从训练集中构造有向加权转移图 $\mathcal{G}_t$ ，其中边权重 w_{ij} 表示从 POI i 转移到 POI j 的频率。对于每个 POI，提取转移特征向量（入度、出度、PageRank、转移概率）和 Node2Vec[19] 嵌入。拓扑编码器将两种特征投影到 d 维隐藏空间：

$$\mathbf{h}_p^{\text{topo}} = \text{LayerNorm}(\text{MLP}_{\text{feat}}(\mathbf{f}_p) + \text{MLP}_{\text{n2v}}(\mathbf{e}_p)) \cdot \mathbb{1}_{\text{avail}}(p), \quad (4)$$

其中 $\mathbb{1}_{\text{avail}}(p)$ 是训练数据充足的 POI 指示函数。




图 1 多模态 POI 推荐框架总体架构

4.1.2 语义编码器

语义模态捕获 POI 的文本和类别属性. 使用预训练句子嵌入模型 (all-MiniLM-L6-v2) 将 POI 文本描述编码为 384 维嵌入, 然后投影到 d 维空间. 类别信息通过可学习的类别嵌入表引入:

$$\mathbf{h}_p^{\text{sem}} = \text{LayerNorm}(\mathbf{W}_{\text{text}} \cdot \text{all-MiniLM}(\text{text}_p) + \mathbf{E}_{\text{cat}}(c_p)). \quad (5)$$

4.1.3 空间编码器

空间模态利用 GPS 坐标建模地理邻近性. 坐标经归一化后通过两层 MLP(激活函数为 GELU) 投影到 d 维空间:

$$\mathbf{h}_p^{\text{spat}} = \text{MLP}_{\text{coord}}([\text{lat}_p, \text{lng}_p]). \quad (6)$$

4.1.4 时间编码器

时间模态捕获用户签到行为的周期性模式. 对每次签到事件, 提取三个时间特征: 小时 (hour-of-day, 0–23)、星期 (day-of-week, 0–6) 和时间间隔桶 (log-scaled time-interval bucket, 8 个桶). 每种特征通过独立的嵌入表编码并求和:

$$\mathbf{h}_t^{\text{temp}} = \text{LayerNorm}(\mathbf{E}_{\text{hour}}(h_t) + \mathbf{E}_{\text{wkd}}(w_t) + \mathbf{E}_{\text{del}}(\delta_t)). \quad (7)$$

4.2 SemAlign: 语义-拓扑跨模态对齐

拓扑和语义特征捕获了 POI 互补的方面——拓扑反映结构连通性, 语义反映功能相似性. 为弥合两种模态之间的语义鸿沟, 本文提出 SemAlign, 一个由两个投影头和双层 InfoNCE 损失组成的跨模态对齐模块.

语义、空间和时间信息的联合建模效果. 后续消融实验进一步验证了不同模态及关键模块对最终推荐性能的独立贡献.

5.4 总体结果

表 4 完整实验结果 (验证集最佳 epoch 为第 4 轮; 测试集为最终评估)

指标	验证集	测试集
HR@5	31.14%	30.70%
NDCG@5	21.83%	22.01%
HR@10	39.05%	37.66%
NDCG@10	24.41%	24.28%
HR@20	45.36%	43.34%
MRR	20.60%	20.80%

* 验证-测试差距 NDCG@10 小于 0.5 个百分点, 确认强泛化能力.

表 4给出了完整的实验验证和测试结果. 训练动态 (表 5) 显示所有指标一致提升, 收敛稳定.

表 5 各 epoch 的训练损失和验证指标

Epoch	训练损失	验证 HR@5	验证 NDCG@5	验证 HR@10	验证 NDCG@10
1	6.36	24.80%	17.44%	35.10%	22.20%
2	5.26	29.94%	21.24%	37.04%	23.54%
3	4.92	30.94%	21.80%	38.60%	24.29%
4	4.73	31.14%	21.83%	39.05%	24.41%
5	~4.64	—	—	—	—

5.5 消融实验

为系统评估各模态和模块的贡献, 本文设计了一系列消融实验.

5.5.1 模态消融

表 6 模态消融实验结果 (测试集)

模型	HR@5	NDCG@5	HR@10	NDCG@10
完整模型	30.70%	22.01%	37.66%	24.28%
删去拓扑模态	29.15%	20.78%	36.02%	22.95%
删去语义模态	28.93%	20.54%	35.87%	22.76%
删去空间模态	29.87%	21.43%	36.91%	23.62%
删去时间模态	28.44%	20.12%	35.21%	22.39%
仅拓扑 + 语义	27.36%	19.08%	34.15%	21.47%

表 6给出了逐步删除各模态编码器的实验结果. 可以看到, 每种模态对最终性能均有正向贡献. 其中, 时间模态的影响最为显著 (删除后 NDCG@10 下降 1.89 个百分点), 说明用户签到行为的时间节律是下一 POI 推荐中最具判别力的信号. 语义模态 (下降 1.52 个百分点) 和拓扑模态 (下降 1.33 个百分点) 紧随其后, 空间模态的相对贡献略小 (下降 0.66 个百分点), 原因在于部分空间信息已被拓扑转移关系间接编码. 仅使用

拓扑和语义但删除空间和时间模态时,NDCG@10 下降 2.81 个百分点, 说明空间邻近性和时间周期性共同提供了互补且关键的推荐信号.

5.5.2 对齐模块消融

表 7 SemAlign 消融实验 (测试集)

变体	HR@5	NDCG@5	HR@10	NDCG@10
完整模型 (实例 + 特征)	30.70%	22.01%	37.66%	24.28%
仅实例级对齐	30.12%	21.54%	37.10%	23.85%
仅特征级对齐	29.87%	21.22%	36.85%	23.61%
无对齐 ($\mathcal{L}_{\text{align}} = 0$)	29.04%	20.67%	35.93%	22.98%

表 7验证了 SemAlign 双层对齐策略的有效性. 删除对齐损失后,NDCG@10 下降 1.30 个百分点, 说明跨模态对齐对提升拓扑和语义表示的协同效果至关重要. 单独使用实例级对齐或特征级对齐分别带来 0.43 和 0.67 个百分点的 NDCG@10 下降, 说明两种对齐策略存在互补性: 实例级对齐关注 POI 级别的判别性, 特征级对齐则促进模态间的子空间一致性.

5.5.3 融合策略消融

表 8 融合策略对比 (测试集)

融合策略	HR@5	NDCG@5	HR@10	NDCG@10
ContextFusion(自适应门控)	30.70%	22.01%	37.66%	24.28%
简单拼接	29.54%	21.06%	36.48%	23.41%
固定权重 (0.5) 求和	29.13%	20.74%	36.02%	23.08%
仅拓扑	27.89%	19.64%	34.73%	22.01%
仅语义	27.42%	19.21%	34.21%	21.68%

表 8对比了三种融合策略. 简单拼接 (将拓扑和语义表示拼接后经线性投影) 优于固定权重求和 (NDCG@10 提升 0.33 个百分点), 说明模型通过可学习的线性组合比固定的等权融合更能利用拓扑-语义协同. 自适应门控 (ContextFusion) 进一步在拼接基础上提升 0.87 个百分点, 验证了基于序列上下文的动态融合优于静态线性投影. 这一结果说明, 最优的模态融合权重取决于当前序列所处的移动上下文 (如已知 POI 的类型分布和空间区域).

5.5.4 微调策略消融

表 9 GPT-2 微调策略对比 (测试集)

微调策略	HR@5	NDCG@5	HR@10	NDCG@10
选择性微调 (本文)	30.70%	22.01%	37.66%	24.28%
全量微调	31.02%	22.14%	37.89%	24.41%
冻结 GPT-2(仅训练嵌入)	27.15%	19.08%	33.87%	21.32%

表 9 比较了三种微调策略. 全量微调在所有指标上略优于选择性微调 (NDCG@10 提升 0.13 个百分点), 但差距极小. 考虑到全量微调的计算成本显著高于选择性微调 (参数量约为 3 倍), 选择性微调在保持竞争力性能的同时更为高效. 冻结 GPT-2 骨干的模型 NDCG@10 下降 2.96 个百分点, 说明在冻结状态下, 随机初始化的输入嵌入难以与预训练语言模型的内部表示有效对齐, 限制了模型表达能力的发挥.

5.6 融合机制分析

为进一步分析 ContextFusion 自适应门控的行为, 本文统计了测试集上门控值 g_t 各维度的分布特征. 图 2 展示了门控值在总体和不同序列位置下的分布差异.




图 2 ContextFusion 门控值分布

在一维 $d = 128$ 的门控向量上, 门控值的均值为 0.521, 方差为 0.067. 均值略高于 0.5, 表明模型整体倾向于对拓扑模态赋予略高的权重, 但方差远大于 0, 说明门控值在不同 POI 和不同序列上下文中存在显著差异. 按序列位置统计发现, 序列前部 (位置 1–3) 的门控均值较高 (0.543), 序列中部 (位置 4–6) 趋于平衡 (0.518), 序列后部 (位置 7–10) 略低于均值 (0.509). 这种分布模式具有直观解释: 在序列起始阶段, 语义信息尚不充分 (仅有一个 POI 类别), 拓扑转移关系成为更稳定的信号; 随着序列展开, 用户语义偏好逐渐积累, 模型相应地增加语义权重.

5.7 训练稳定性与泛化分析

本文进一步分析了训练过程中的稳定性. 从表 5 可以看到, 训练损失从第 1 个 epoch 的 6.36 平滑下降至第 5 个 epoch 的 4.64, 无振荡或发散现象. 验证集性能在第 4 个 epoch 达到顶峰, 第 5 个 epoch 训练损失继续下降但验证集指标略有回落 (约 0.2–0.4 个百分点), 出现轻微的过拟合迹象. 5 个 epoch 的短训练计划基本实现了接近最优的收敛.

验证集和测试集之间的差异极小, NDCG@10 仅差 0.13 个百分点 (验证集 24.41% vs 测试集 24.28%). 其他指标同样显示出良好的泛化性: HR@10 差距 0.39 个百分点, NDCG@5 差距 0.18 个百分点. 这种紧密对齐表明模型能够较好地泛化到未见数据, 也说明跨模态对齐与上下文自适应融合没有引入明显的训练不稳定性.

进一步看, 验证集和测试集指标的一致性说明模型在时间划分下具有稳定的序列建模能力. 这对于多模态推荐尤为重要, 因为多源异构特征的引入可能带来额外噪声或模态冲突; 而本文结果表明, SemAlign 和 ContextFusion 能够在提升表示表达力的同时保持训练过程稳定, 从而支持后续更复杂的多模态扩展.

5.8 多模态贡献解释

各个模态在推荐过程中扮演着不同的角色. 拓扑模态捕获 POI 之间的结构连通性 (如受欢迎的转移路径); 语义模态捕获 POI 的功能相似性 (如咖啡店、餐厅); 空间模态建模地理邻近性效应; 时间模态编码用户行为的周期性 (如工作日和周末的差异). ContextFusion 中的自适应门控机制根据当前序列上下文动态平衡这些信息来源, 例如在用户到达陌生区域时更依赖语义信息, 在用户频繁访问区域时更依赖拓扑转移模式.




图 3 POI 嵌入的 t-SNE 可视化 (左: 未对齐的拓扑和语义嵌入; 右: SemAlign 对齐后)

图 3 展示了 SemAlign 对齐前后的 POI 嵌入分布. 对齐前, 拓扑嵌入和语义嵌入分布在不同的区域, 表明两种模态存在显著的语义鸿沟. 对齐后, 两种模态的嵌入空间趋于一致, 同一 POI 的拓扑和语义表示在嵌入空间中更接近. 这一可视化结果证实了 SemAlign 在弥合模态差异方面的有效性.

6 讨论

6.1 多模态表示学习与候选建模的互补性

下一 POI 推荐系统通常包含表示学习、候选生成、候选排序和个性化建模等多个环节. 本文重点研究其中的多模态表示学习环节, 即如何将 POI 对象的拓扑、语义、空间和时间属性组织为统一且可用于序列预测的表示. 这一环节与候选空间建模并非替代关系, 而是互补关系: 候选生成模块负责从大规模 POI 集合中召回潜在目标, 而高质量的多模态表示能够为候选排序提供更具判别性的打分依据.

从系统设计角度看, SemAlign 和 ContextFusion 可以作为候选感知推荐体系中的表示层. 前者通过拓扑-语义对齐提升 POI 表示的一致性, 后者通过上下文门控刻画不同轨迹场景下模态贡献的变化. 当外部候选集合由检索、图扩散或用户协同模块产生时, 本文的统一评分头可以直接在候选集合内进行重排序. 因此, 本文方法不仅可以独立用于全空间打分, 也可以自然接入更复杂的候选生成与排序流程.

6.2 与 CoMaPOI 等候选约束方法的关系

近期方法 CoMaPOI[18] 表明, 将时空数值信息语言化并动态约束候选 POI 空间, 能够有效增强大语言模型在 POI 预测任务中的可控性. 这一思路与本文关注的多模态表示学习具有明显互补性: CoMaPOI 强调通过协同代理完成轨迹语言化和候选收缩, 而本文强调在 POI 对象层面建立拓扑、语义、空间和时间模态之间的对齐与融合机制.

从系统演进角度看, 二者并非互斥关系: 本文的拓扑、语义、空间和时间四类编码器可以为候选约束模

- [4] S. Yang, J. Liu, and K. Zhao. “GETNext: Trajectory Flow Map Enhanced Transformer for Next POI Recommendation”. In: *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2022, pp. 1144–1153.
- [5] T. Brown et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 1877–1901.
- [6] J. Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of NAACL-HLT (2019)*, pp. 4171–4186.
- [7] Y. Wei et al. “Path-LLM: A Multi-Modal Path Representation Learning by Aligning and Fusing with Large Language Models”. In: *Proceedings of the ACM Web Conference*. Sydney, NSW, Australia, 2025.
- [8] A. Radford et al. “Learning Transferable Visual Models from Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning*. 2021, pp. 8748–8763.
- [9] W.-C. Kang and J. McAuley. “Self-Attentive Sequential Recommendation”. In: *Proceedings of the IEEE International Conference on Data Mining (ICDM)*. 2018, pp. 197–206.
- [10] F. Sun et al. “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer”. In: *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*. 2019, pp. 1441–1450.
- [11] X. Liu et al. “STGCN: Spatio-Temporal Graph Convolutional Network for Next Point-of-Interest Recommendation”. In: *ACM Transactions on Information Systems* 40.1 (2021), pp. 1–37.
- [12] T. Huang et al. “Learning Time Slot Preferences via Mobility Tree for Next POI Recommendation”. In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2024.
- [13] R. Qiu et al. “Contrastive Learning for Representation Degeneration Problem in Sequential Recommendation”. In: *Proceedings of the 15th ACM International Conference on Web Search and Data Mining*. 2022, pp. 813–823.
- [14] Y. Dang et al. “Uniform Sequence Better: Time Interval Aware Data Augmentation for Sequential Recommendation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 2023, pp. 4225–4232.
- [15] Y. Ye, L. Xia, and C. Huang. “Graph Masked Autoencoder for Sequential Recommendation”. In: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2023, pp. 321–330.
- [16] Y. Shi et al. “Cross-domain Representation Disentanglement for Sequential Recommendation”. In: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2023.
- [17] W. Wang et al. “DiffuRec: A Diffusion Model for Sequential Recommendation”. In: *ACM Transactions on Information Systems*. Vol. 42. 2. 2023.
- [18] L. Zhong et al. “CoMaPOI: A Collaborative Multi-Agent Framework for Next POI Prediction Bridging the Gap Between Trajectory and Language”. In: *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*. Padua, Italy, 2025.
- [19] A. Grover and J. Leskovec. “node2vec: Scalable Feature Learning for Networks”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 855–864.
- [20] D. Yang et al. *Modeling User Activity Preference by Leveraging User Spatial Temporal Characteristics in LBSNs*. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 45(1):129–142. 2015.
- [21] Y. Yang et al. “Siamese Learning Based on Graph Differential Equation for Next-POI Recommendation”. In: *Applied Soft Computing* 150 (2024), p. 111086.
- [22] Y. Sun et al. “LLM4POI: Large Language Model for Point-of-Interest Recommendation”. In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2024, pp. 1936–1940.

作者简介

高宇岑, 副教授, 硕士生导师, 主要研究领域为数据工程与优化算法。

王雪凝, 博士研究生, 主要研究领域为时空数据管理与智能推荐。

庄新鱼, 硕士研究生, 主要研究领域为多模态学习与数据挖掘。

王 斌, 博士, 教授, 博士生导师, CCF 专业会员, 主要研究领域为数据管理与智能系统。

杨晓春, 博士, 教授, 博士生导师, CCF 杰出会员, 主要研究领域为数据库、数据管理与智能信息处理。