

面向下一兴趣点推荐的跨模态自适应融合与检索方法* (专刊: 多模态数据管理及融合技术)

高宇岑¹, 王雪凝², 庄新鱼², 王斌², 杨晓春¹

¹(东北大学软件学院, 沈阳, 110169)

²(东北大学计算机科学与工程学院, 沈阳, 110169)

通讯作者: 杨晓春, E-mail: yangxc@mail.neu.edu.cn

摘 要: 随着智慧城市与位置服务应用的发展, 城市轨迹数据呈现出模态各异、动态演化和规模庞大等特点: 兴趣点类别与文本描述刻画功能语义, 兴趣点转移关系揭示城市活动拓扑结构, 空间位置与时间上下文共同约束用户移动过程, 用户签到序列则反映行为时序依赖。下一兴趣点推荐需要综合利用上述多模态信息预测用户未来访问位置, 但现有方法仍存在三方面不足: 一是缺少对语义、拓扑与空间等多模态轨迹信息的统一表示与跨模态关联建模, 难以充分挖掘不同模态之间的互补性; 二是多采用静态融合策略, 难以适应不同用户状态与移动场景下信息贡献的动态变化; 三是候选生成过程通常未区分不同来源的检索代价, 面对大规模兴趣点集合时容易引入冗余检索开销。针对上述问题, 本文提出一种面向下一兴趣点推荐的跨模态自适应融合与检索方法 CAFR。首先, 构建语义、拓扑和空间三类兴趣点表示, 并设计跨模态交互与一致性约束机制, 以增强不同模态之间的信息传递和表示对齐能力; 其次, 引入上下文感知的自适应融合机制, 利用用户偏好、时间上下文和当前轨迹状态动态调整各模态贡献, 生成统一的兴趣点表示; 最后, 提出代价感知的自适应级联多索引检索策略, 优先访问低代价候选来源, 并根据候选充分性与不确定性决定是否扩展高代价索引, 从而在候选覆盖率与在线检索效率之间取得平衡。在纽约和东京两个真实城市签到数据集上的实验结果表明, 本文方法能够有效利用多模态轨迹信息, 提升下一兴趣点推荐的命中能力和排序质量, 同时降低候选检索开销, 为多模态城市轨迹数据的融合建模与高效应用提供了一种有效方案。

关键词: 多模态数据融合; 城市计算; 下一兴趣点推荐

中图法分类号: TP391

中文引用格式: 高宇岑, 王雪凝, 庄新鱼, 王斌, 杨晓春. 面向下一兴趣点推荐的跨模态自适应融合与检索方法. 软件学报, 20XX, XX(XX):1-XX. <http://www.jos.org.cn/1000-9825/0000.htm>

英文引用格式: Gao YC, Wang XN, Zhuang XY, WANG B, YANG XC. Cross-modal Adaptive Fusion and Retrieval for Next POI Recommendation. Ruan Jian Xue Bao/Journal of Software, 20XX, XX(XX):1-XX (in Chinese). <http://www.jos.org.cn/1000-9825/0000.htm>

Cross-modal Adaptive Fusion and Retrieval for Next POI Recommendation

GAO Yu-Cen¹, WANG Xue-Ning², ZHUANG Xin-Yu², WANG Bin², YANG Xiao-Chun¹

¹(Software College, Northeastern University, Shenyang 110169, China)

²(School of Computer Science and Engineering, Northeastern University, Shenyang 110169, China)

Abstract: With the rapid development of smart cities and location-based services, urban trajectory data have exhibited three prominent characteristics: heterogeneous modalities, dynamic evolution, and large-scale candidate spaces. POI categories and textual descriptions characterize functional semantics, POI transition relations reveal urban activity topology, spatial locations and temporal contexts jointly constrain user mobility, while user check-in sequences reflect sequential behavioral dependencies. Next Point-of-Interest (POI) recommendation requires the effective integration of such multimodal information to predict users' future visits. However, existing methods still suffer from three limitations: they lack unified representation learning and cross-modal correlation modeling for multimodal trajectory information such as semantics, topology, and space; they mostly adopt static fusion strategies and thus cannot adapt to varying modality contributions under different user states and mobility contexts;

* 基金项目: 国家重点研发计划项目 (2024YFF0617702); 国家自然科学基金项目 (U22A2025, 62232007, U23A20309); 高等学校学科创新引智计划 (111 计划) 项目 (B16009); 蚂蚁集团研究计划项目 (2025021900003); 中央高校基本科研业务费专项资金项目 (N2417007)

and their candidate generation procedures are usually unaware of retrieval costs across different sources, leading to redundant retrieval overhead over large POI spaces. To address these challenges, this paper proposes a Cross-modal Adaptive Fusion and Retrieval method for next POI recommendation, termed CAFR. Specifically, we first construct semantic, topological, and spatial POI representations, and design cross-modal interaction and consistency regularization mechanisms to enhance information transfer and representation alignment across modalities. Then, we develop a context-aware adaptive fusion mechanism that dynamically adjusts modality contributions according to users' preferences, temporal contexts, and current trajectory states, thereby generating unified POI representations. Finally, we propose a cost-aware adaptive cascaded multi-index retrieval strategy, which prioritizes low-cost candidate sources and selectively expands to high-cost indexes according to candidate sufficiency and uncertainty, achieving a balance between candidate coverage and online retrieval efficiency. Experiments on two real-world urban check-in datasets, NYC and TKY, demonstrate that the proposed method effectively exploits multimodal trajectory information, improves hit performance and ranking quality for next POI recommendation, and meanwhile reduces candidate retrieval overhead. This study provides an effective solution for multimodal urban trajectory fusion modeling and efficient applications.

Key words: Multimodal Data Fusion; Urban Computing; Next POI Recommendation

随着移动互联网、智能终端以及智慧城市基础设施的快速发展，城市空间中持续产生大量用户移动轨迹数据^[1]。这些数据不仅记录了用户的位置变化过程，还关联了兴趣点文本描述、类别属性、拓扑约束、空间分布以及时间行为规律等多模态信息。例如，用户一次完整的城市活动过程通常同时包含访问地点、移动路径、停留时间和环境语义等多维信息。然而，这类城市轨迹数据通常具有模态各异、动态演化和规模庞大等特点，不同数据源在结构形式、语义表达和信息粒度方面存在显著差异，如何实现多模态城市轨迹数据的有效融合与应用，成为支撑城市智能服务的重要研究问题。

在众多城市智能应用中，下一兴趣点（Point-of-Interest, POI）推荐旨在根据用户历史移动行为预测其未来可能访问的位置，在个性化出行路线规划、周边生活服务推送、商圈客流预测与门店选址决策等场景中具有广泛应用价值。如图 1 所示，不同于传统序列推荐任务，下一兴趣点推荐不仅依赖用户访问序列中的时间依赖关系，还受到兴趣点的语义属性、拓扑转移约束和空间关系等多方面因素影响。因此，该任务为研究多模态城市轨迹数据的融合与应用提供了典型验证场景。




图 1 下一兴趣点推荐场景示意图

近年来，研究人员尝试利用深度学习方法对不同类型的城市轨迹信息进行建模，并取得了一定进展^[2]。然而，面对模态各异、动态演化且规模庞大的城市轨迹数据，现有方法仍存在以下不足。首先，不同模态数据通常具有不同的数据结构和语义空间^[3]，现有方法缺少对语义、拓扑与空间等多模态轨迹信息的统一表

示与跨模态关联建模, 简单特征拼接难以充分挖掘多模态信息之间的互补价值。其次, 现有融合方法大多采用静态融合策略, 默认不同模态在不同用户和不同场景下具有相似的重要程度, 难以适应城市移动行为动态演化所带来的模态贡献变化。最后, 面对大规模兴趣点集合, 候选生成过程通常未区分不同信息源的访问代价, 也难以依据中间候选结果自适应调整检索范围, 从而带来不必要的在线检索开销。

针对上述挑战, 本文提出一种面向下一兴趣点推荐的跨模态自适应融合与检索方法。该方法首先构建语义、拓扑和空间多模态表示, 并通过跨模态交互与一致性约束实现多模态轨迹信息的统一表示与对齐; 在此基础上, 进一步提出上下文感知的自适应融合策略, 根据用户状态和轨迹上下文动态调整不同模态信息的贡献; 最后, 设计代价感知的自适应级联多索引检索机制, 在保证候选质量的同时降低冗余检索开销。最终结合序列建模方法, 构建面向下一兴趣点预测的智能推荐框架。

本文的主要贡献如下:

(1) 提出一种面向下一兴趣点推荐的多模态城市轨迹表示学习与跨模态对齐方法, 统一建模语义、拓扑和空间等异构信息, 并通过跨模态交互与一致性约束增强不同模态之间的关联建模能力。

(2) 提出一种上下文感知自适应融合机制, 利用用户偏好、时间上下文与当前轨迹状态动态调整不同模态的贡献, 提高模型对动态移动场景的适应能力。

(3) 提出一种代价感知的自适应级联多索引检索机制, 将候选生成建模为低代价优先、按需扩展的两阶段检索过程, 在保证候选质量的同时降低在线检索开销。

(4) 在纽约和东京两个真实城市签到数据集上开展实验, 从推荐精度、排序质量和检索效率等方面验证了整体框架的有效性。

1 相关工作

1.1 多模态数据表示对齐、融合与检索

随着人工智能应用场景的不断扩展, 文本、图结构、时空轨迹以及传感数据等多模态数据逐渐成为智能决策的重要信息来源。由于不同模态在数据结构、表示空间以及语义表达方式方面存在显著差异, 如何实现异构信息的统一表示、跨模态语义对齐与有效融合, 已经成为数据管理与人工智能领域的重要研究方向。与此同时, 在面向大规模数据应用时, 仅获得融合表示仍然不足, 往往还需要进一步支持跨模态匹配、候选检索与高效访问, 因而“表示—对齐—融合—检索”逐渐成为多模态智能应用中的关键技术链条。

早期研究主要关注单一模态数据的表示学习, 通过深度神经网络将原始数据映射到低维语义空间, 为后续跨模态建模奠定基础。例如, BERT 利用大规模语料预训练学习上下文语义表示, 为文本知识建模提供了有效方法^[4]; node2vec 通过结合网络结构信息和随机游走策略学习图节点表示, 有效捕获关系数据中的结构特征^[5]。这类单模态表示学习方法分别从文本语义、关系结构等角度提升了数据表征能力, 但由于不同模态之间仍处于彼此独立的表示空间, 难以直接支撑异构信息的联合理解与协同检索。

随着多模态应用需求的发展, 研究者进一步关注不同模态之间的语义关联、表示对齐与融合建模。例如, CLIP 通过构建视觉与语言之间的对比学习目标, 将不同模态映射到统一语义空间, 实现跨模态知识迁移^[6]。近年来, 多模态融合研究又逐渐从静态表示拼接发展到深层交互建模, 基于注意力机制、对比学习和跨模态 Transformer 的方法能够显式捕获不同模态之间的关联关系, 并根据任务需求学习更加有效的融合表示; 在此基础上, 统一表示空间也为跨模态匹配与检索提供了支持。然而, 现有研究大多面向视觉—语言等通用场景设计, 对于具有强领域约束的专业数据, 如城市轨迹中的拓扑关系、空间分布和用户行为模式, 仍需要结合具体应用特点设计更加有效的表示组织、融合建模与检索机制。

1.2 城市轨迹与下一兴趣点推荐

城市轨迹数据挖掘旨在从用户移动过程中发现空间活动规律和行为模式,是智慧城市和位置服务领域的重要研究方向。Zheng 等系统总结了轨迹表示、模式发现以及移动行为分析等关键问题,为后续城市轨迹智能分析奠定了基础^[7]。随着基于位置服务 (Location-Based Services, LBS) 的快速发展,下一兴趣点推荐逐渐成为城市轨迹分析中的重要任务,其核心在于根据用户历史访问行为预测未来可能到达的位置。Sánchez 与 Bellogín 进一步从推荐系统实验角度对基于位置社交网络的 POI 推荐方法进行了系统综述^[8]。国内方面,汤佳欣等综述了深度学习方法在 POI 推荐中的应用进展^[9],刘广腾等则从注意力机制与图神经网络角度对下一兴趣点推荐算法进行了系统梳理^[10]。

围绕下一兴趣点推荐,已有研究首先从时间因素和序列依赖角度建模用户移动规律。早期方法主要依赖用户访问频率、时间周期和行为共现等人工设计特征,其中 Yuan 等较早将时间维度系统性地融入 POI 推荐,提出了基于时间感知的协同过滤方法^[11]。随着深度学习的发展,序列建模方法被广泛应用于该任务,SASRec 利用自注意力机制捕获用户行为序列中的长期依赖关系^[12],BERT4Rec 进一步通过双向 Transformer 结构学习用户行为序列上下文表示^[13]。这类方法强调用户行为的时序演化,对理解动态兴趣偏好具有重要作用。

由于下一兴趣点推荐还具有显著的空间约束和移动连续性,研究者进一步引入空间因素与时空联合建模方法。Huang 等较早将注意力机制与时空 LSTM 网络相结合,用于建模 POI 序列中的时空依赖关系^[14];Zhao 等提出时空门控网络 STGN,通过耦合 LSTM 中的时空门控单元建模用户长短期移动偏好^[15];STAN 利用时空注意力机制刻画用户移动过程中的距离和时间间隔影响^[16];GETNext 通过轨迹流图增强 Transformer 模型,挖掘用户移动过程中的空间转移模式^[17];STGCAN 利用时空图卷积注意力网络同时学习空间邻接关系和时间动态变化,提高了复杂时空环境下的预测能力^[18]。此外,Yan 等进一步通过时空超图学习方法捕获用户轨迹中的高阶 POI 关联关系^[19]。尽管上述方法有效提升了下一兴趣点推荐性能,但其主要关注用户轨迹序列中的时间依赖与空间规律建模,对于兴趣点自身包含的丰富语义属性、拓扑结构以及多模态上下文信息利用仍然有限。

1.3 面向下一兴趣点推荐的多模态融合与检索方法

为了进一步利用兴趣点自身属性以及用户上下文信息,近年来研究者开始探索面向下一兴趣点推荐的多模态融合方法。Chang 等提出基于内容感知的层次化兴趣点表示方法,通过融合兴趣点属性信息增强用户兴趣建模能力^[20]。Chen 等研究发现,道路网络结构和交通语义信息之间具有互补关系,并提出融合结构信息和语义信息的表示学习方法^[21]。石美惠等提出融合全局静态特征与局部动态偏好的下一兴趣点推荐方法,通过构建多模态信息网络与层级注意力机制联合建模 POI 的多维特征^[22]。Wang 等提出 DSDRec 方法,利用深度语义提取与扩散模型增强 POI 表示的语义判别能力^[23]。Zeng 等进一步结合全局与局部超图学习与语义增强机制,提升 POI 推荐中的语义感知与结构建模能力^[24]。

除了融合建模之外,大规模下一兴趣点推荐还面临候选生成与在线检索效率问题。对于真实城市场景中的海量 POI 集合,推荐系统通常需要先从候选集合中进行召回,再执行精细排序,因此检索阶段的候选覆盖率、索引访问代价与响应效率会直接影响最终系统性能。然而,现有相关研究大多更关注多模态特征增强、轨迹理解或排序模型设计,较少从检索视角系统考虑多模态候选源的组织方式、访问顺序以及按需扩展策略,对于如何在多种信息源之间实现代价可控的自适应候选检索仍缺乏深入研究。

因此,现有面向下一兴趣点推荐的多模态方法仍存在三方面不足:一是通常针对特定模态进行增强,缺少对拓扑、语义、空间和行为等多模态信息的统一组织与协同建模;二是不同模态在不同用户状态和移动场景中的有效性存在差异,固定融合方式难以动态调整不同信息源的贡献;三是在候选生成阶段,现有方法较少显式考虑多模态候选源的访问代价与检索计划优化,难以兼顾候选质量与在线效率。因此,如何设计能够有效关联多模态轨迹信息、根据上下文实现自适应融合、并支持代价感知候选检索的下一兴趣点推

荐方法, 仍然是值得研究的问题。针对上述不足, 本文从多模态城市轨迹数据融合角度出发, 构建统一的数据表示框架, 并设计跨模态交互、上下文感知融合与代价感知检索机制, 实现不同来源信息的有效协同。

2 问题定义

本文研究多模态城市轨迹数据融合驱动的下一兴趣点推荐问题。在该场景中, 用户移动行为通常以连续签到轨迹形式存在, 并关联兴趣点语义信息、访问拓扑关系、空间关系以及用户行为上下文等多模态数据。本文旨在利用这些信息学习用户移动规律, 并预测用户未来可能访问的兴趣点。

设用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$, 兴趣点集合为 $\mathcal{P} = \{p_1, p_2, \dots, p_M\}$ 。用户 u 在时间 t_i 访问兴趣点 p_i 形成一条签到记录:

$$x_i^u = (u, p_i, t_i). \quad (1)$$

按照时间顺序排列用户历史签到记录, 得到用户历史访问轨迹:

$$\mathcal{H}_u^{(n)} = [x_1^u, x_2^u, \dots, x_n^u], \quad t_1 < t_2 < \dots < t_n. \quad (2)$$

除用户历史轨迹外, 城市环境中还包含与用户移动行为相关的多模态辅助信息, 包括兴趣点语义信息、由历史轨迹构建的拓扑关系信息、空间关系信息以及用户行为上下文信息。记这些信息集合为:

$$\mathcal{D} = \{\mathcal{D}_{sem}, \mathcal{D}_{topo}, \mathcal{D}_{spatial}, \mathcal{D}_{traj}\}. \quad (3)$$

其中, $\mathcal{D}_{sem}$ 、 $\mathcal{D}_{topo}$ 、 $\mathcal{D}_{spatial}$ 和 $\mathcal{D}_{traj}$ 分别表示语义信息、拓扑关系信息、空间关系信息以及用户行为上下文信息。

下一兴趣点推荐任务旨在学习评分函数

$$f(u, \mathcal{H}_u^{(n)}, \mathcal{D}, p), \quad (4)$$

用于度量用户 u 在给定历史轨迹和多模态城市信息条件下访问候选兴趣点 p 的可能性。

根据评分函数对候选兴趣点进行排序, 并输出用户 u 的 Top- K 推荐列表:

$$\mathcal{R}_u^K = [p_{r_1}, p_{r_2}, \dots, p_{r_K}], \quad (5)$$

其中 $p_{r_i} \in \mathcal{P}$ 表示推荐结果中的兴趣点。本文目标是通过有效融合多模态城市轨迹信息, 使用户真实访问的下一兴趣点 p_{n+1} 能够在推荐列表 $\mathcal{R}_u^K$ 中获得更高排名。

3 跨模态自适应融合与检索方法 CAFR

城市轨迹数据具有典型的多模态特征, 不同来源的数据从不同角度描述用户移动行为。用户签到序列反映访问过程中的时序依赖, 兴趣点类别和文本描述刻画地点功能语义, 兴趣点之间的转移关系描述城市活动中的行为拓扑, 空间位置则提供地理约束。与此同时, 不同用户在不同时间和移动场景下对各类信息的依赖程度并不相同。因此, 下一兴趣点推荐不仅需要统一建模多模态兴趣点信息, 还需要根据用户画像和当前轨迹上下文动态调整信息贡献, 并在大规模候选空间中控制检索代价。

针对上述问题, 本文提出跨模态自适应融合与检索模型 (Cross-modal Adaptive Fusion and Retrieval, CAFR)。整体框架如图 2 所示, CAFR 包含五个核心模块: 多模态表示学习与跨模态对齐、用户画像编码与上下文感知自适应融合、代价感知的自适应级联多索引检索、用户画像条件化的时空序列建模, 以及候选重排序与模型优化。整体计算流程为: 首先编码兴趣点语义、拓扑和空间信息, 并通过跨模态交互与对




图 2 多模态轨迹数据自适应融合驱动的下一兴趣点推荐总体架构

齐约束缓解异构模态之间的表示偏差；其次构建用户画像，并以画像为条件动态生成模态融合权重；然后采用低代价优先、按需扩展的级联多索引检索策略生成动态候选池；进一步将画像作为前缀条件输入因果Transformer，对时空增强历史轨迹进行建模；最后在候选池约束下进行神经匹配和重排序，得到 Top- K 下一兴趣点推荐结果。

3.1 多模态表示学习与跨模态对齐

对于兴趣点 p ，本文分别从语义、拓扑和空间三个角度构建基础模态表示。

语义模态由类别嵌入和文本特征共同给出：

$$\mathbf{e}_{p,c} = \mathbf{E}_c[c_p], \quad \mathbf{e}_{p,x} = \text{MLP}_{\text{text}}(\mathbf{x}_p^{\text{text}}), \quad (6)$$

$$\mathbf{e}_p^{\text{sem}} = \text{LN}(\text{MLP}_{\text{sem}}[\mathbf{e}_{p,c}; \mathbf{e}_{p,x}]), \quad (7)$$

其中 $[\cdot; \cdot]$ 表示向量拼接， $\text{LN}(\cdot)$ 表示层归一化。

拓扑模态用于刻画兴趣点在用户移动网络中的结构角色。本文根据训练集连续签到构建有向转移图 $\mathcal{G} = (\mathcal{P}, \mathcal{E})$ ，并同时利用转移统计特征 $\mathbf{x}_p^{\text{trans}}$ 和 Node2Vec 表示 $\mathbf{x}_p^{\text{n2v}}$ ：

$$\mathbf{e}_p^{\text{topo}} = \text{LN}(\text{MLP}_{\text{topo}}[\mathbf{x}_p^{\text{trans}}; \mathbf{x}_p^{\text{n2v}}]). \quad (8)$$

空间模态则由兴趣点归一化地理坐标 $\mathbf{l}_p = [\text{lat}_p, \text{lon}_p]$ 编码得到：

$$\mathbf{e}_p^{\text{spa}} = \text{LN}(\text{MLP}_{\text{spa}}(\mathbf{l}_p)). \quad (9)$$

独立模态编码容易造成不同信息源之间的割裂。为增强模态互补性，本文引入跨模态交互模块：

$$(\tilde{\mathbf{e}}_p^{\text{sem}}, \tilde{\mathbf{e}}_p^{\text{topo}}, \tilde{\mathbf{e}}_p^{\text{spa}}) = \text{CMI}(\mathbf{e}_p^{\text{sem}}, \mathbf{e}_p^{\text{topo}}, \mathbf{e}_p^{\text{spa}}), \quad (10)$$

其中 $\text{CMI}(\cdot)$ 通过多头注意力在语义、拓扑和空间表示之间传递信息。以模态 a 吸收模态 b 的信息为例:

$$\text{Attn}(\mathbf{Q}_a, \mathbf{K}_b, \mathbf{V}_b) = \text{softmax}\left(\frac{\mathbf{Q}_a \mathbf{K}_b^\top}{\sqrt{d}}\right) \mathbf{V}_b, \quad (11)$$

交互后的表示能够同时感知兴趣点功能属性、移动拓扑和地理约束。进一步地, 本文采用跨模态对齐损失约束同一兴趣点不同模态表示在共享空间中接近。对于批次内 B 个兴趣点, 模态 a 和 b 之间的 InfoNCE 损失为:

$$\mathcal{L}_{a,b} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{sim}(\tilde{\mathbf{e}}_i^a, \tilde{\mathbf{e}}_i^b)/\tau)}{\sum_{j=1}^B \exp(\text{sim}(\tilde{\mathbf{e}}_i^a, \tilde{\mathbf{e}}_j^b)/\tau)}, \quad (12)$$

其中 $\text{sim}(\cdot)$ 为余弦相似度, τ 为温度参数。总对齐损失为:

$$\mathcal{L}_{\text{align}} = \mathcal{L}_{\text{sem}, \text{topo}} + \mathcal{L}_{\text{sem}, \text{spa}} + \mathcal{L}_{\text{topo}, \text{spa}}. \quad (13)$$

3.2 用户画像编码与上下文感知自适应融合

不同用户对语义、拓扑和空间信息的依赖程度存在显著差异。为刻画用户偏好, 本文从训练历史中构建用户画像, 包括类别偏好、时间偏好、空间分布和历史访问分布。设用户 u 对类别 c 的访问偏好为 $\pi_u^{\text{cat}}[c]$, 时间偏好为 π_u^{time} , 空间中心和离散程度为 π_u^{spa} , 历史访问 POI 集合为 $\mathcal{H}_u^{\text{poi}}$ 。为了刻画用户对具体兴趣点的访问偏好, 本文为每个兴趣点维护一张可学习的 ID 嵌入表 $\mathbf{E}^{\text{id}} \in \mathbb{R}^{|\mathcal{P}| \times d}$, 其中 $\mathbf{e}_p^{\text{id}} = \mathbf{E}^{\text{id}}[p]$ 表示兴趣点 p 的可学习 ID 表示。设用户 u 对兴趣点 p 的历史访问频次为 $n_{u,p}$, 其归一化访问权重为 $\bar{w}_{u,p} = \frac{n_{u,p}}{\sum_{p' \in \mathcal{H}_u^{\text{poi}}} n_{u,p'}}$ 。则各部分分别编码为:

$$\mathbf{l}_u^{\text{cat}} = f_{\text{cat}}(\pi_u^{\text{cat}}), \quad \mathbf{l}_u^{\text{time}} = f_{\text{time}}(\pi_u^{\text{time}}), \quad \mathbf{l}_u^{\text{spa}} = f_{\text{spa}}(\pi_u^{\text{spa}}), \quad \mathbf{l}_u^{\text{poi}} = \sum_{p \in \mathcal{H}_u^{\text{poi}}} \bar{w}_{u,p} \mathbf{e}_p^{\text{id}}. \quad (14)$$

最终用户画像表示为:

$$\mathbf{l}_u = \text{LN}\left(\text{MLP}_{\text{profile}}[\mathbf{l}_u^{\text{cat}}; \mathbf{l}_u^{\text{time}}; \mathbf{l}_u^{\text{spa}}; \mathbf{l}_u^{\text{poi}}]\right). \quad (15)$$

在此基础上, 以用户画像和候选兴趣点的多模态表示为条件, 生成用户-兴趣点级别的自适应模态权重:

$$\mathbf{g}_{u,p} = \text{MLP}_{\text{gate}}([\tilde{\mathbf{e}}_p^{\text{topo}}; \tilde{\mathbf{e}}_p^{\text{sem}}; \tilde{\mathbf{e}}_p^{\text{spa}}; \mathbf{l}_u]), \quad (16)$$

$$[\alpha_{u,p}^{\text{topo}}, \alpha_{u,p}^{\text{sem}}, \alpha_{u,p}^{\text{spa}}] = \text{softmax}(\mathbf{g}_{u,p}), \quad (17)$$

其中 $\alpha_{u,p}^{\text{topo}} + \alpha_{u,p}^{\text{sem}} + \alpha_{u,p}^{\text{spa}} = 1$ 。对于兴趣点 p , 面向用户 u 的融合表示为:

$$\mathbf{h}_{u,p} = \alpha_{u,p}^{\text{topo}} \tilde{\mathbf{e}}_p^{\text{topo}} + \alpha_{u,p}^{\text{sem}} \tilde{\mathbf{e}}_p^{\text{sem}} + \alpha_{u,p}^{\text{spa}} \tilde{\mathbf{e}}_p^{\text{spa}}. \quad (18)$$

该机制使模态权重同时随用户画像和候选兴趣点特征动态变化, 即同一兴趣点在不同用户条件下、不同兴趣点在同一用户条件下均可具有不同的融合权重。例如, 规律通勤用户可更多依赖拓扑转移信息, 探索型用户则可能更多依赖语义和空间信息。

3.3 代价感知的自适应级联多索引检索

在大规模 POI 集合上直接计算所有候选的神经匹配分数开销较高。本文将候选生成建模为代价感知的自适应多索引 Top- N 查询过程: 先访问低代价索引, 当中间候选覆盖不足或分数分布不确定时, 再按需访

问高代价索引。本文将候选来源划分为低代价集合和高代价集合：

$$\mathcal{M}_{cheap} = \{history, user, transition, category, temporal, popularity\}, \quad (19)$$

$$\mathcal{M}_{exp} = \{spatial, history_transition, trajectory_neighbor\}, \quad (20)$$

其中，低代价来源主要依赖历史列表、转移邻接表、倒排索引和流行度列表；高代价来源涉及空间近邻、扩展历史转移或轨迹邻域检索，通常具有更高索引访问和候选合并开销。

第一阶段候选集合为：

$$\mathcal{C}_u^{(1)} = \bigcup_{r \in \mathcal{M}_{cheap}} \mathcal{C}_u^r, \quad (21)$$

其中 $\mathcal{C}_u^r = \{(p, \rho_r(u, p))\}$ 表示来源 r 返回的候选及其源内原始分数。为消除不同来源分数量纲差异，本文进行源内归一化：

$$\bar{\rho}_r(u, p) = \frac{\rho_r(u, p)}{\max_{p' \in \mathcal{C}_u^r} \rho_r(u, p') + \epsilon}. \quad (22)$$

对同一 POI 被多个来源召回的情况，采用加权累加得到第一阶段融合检索分数：

$$R_u^{(1)}(p) = \sum_{r \in \mathcal{M}_{cheap}} \beta_r \bar{\rho}_r(u, p). \quad (23)$$

同时记录候选来源标记：

$$\mathbf{f}_u^{src}(p) = [f_{u,p}^1, f_{u,p}^2, \dots, f_{u,p}^M], \quad f_{u,p}^r = \mathbb{I}[p \in \mathcal{C}_u^r]. \quad (24)$$

是否执行第二阶段由第一阶段候选数量和分数熵共同决定。记 $n_u^{(1)} = |\mathcal{C}_u^{(1)}|$ ，并将第一阶段融合分数归一化为：

$$\pi_u^{(1)}(p) = \frac{\exp(R_u^{(1)}(p)/\tau_r)}{\sum_{p' \in \mathcal{C}_u^{(1)}} \exp(R_u^{(1)}(p')/\tau_r)}. \quad (25)$$

归一化熵定义为：

$$\bar{H}_u^{(1)} = -\frac{\sum_{p \in \mathcal{C}_u^{(1)}} \pi_u^{(1)}(p) \log \pi_u^{(1)}(p)}{\log(n_u^{(1)} + \epsilon)}. \quad (26)$$

若候选数量不足或候选分数分布过于平坦，则触发高代价扩展：

$$g_u = \mathbb{I}[n_u^{(1)} < \theta_n \vee \bar{H}_u^{(1)} > \theta_H]. \quad (27)$$

当 $g_u = 1$ 时，执行第二阶段检索并更新融合检索分数：

$$\mathcal{C}_u^{(2)} = \bigcup_{r \in \mathcal{M}_{exp}} \mathcal{C}_u^r, \quad (28)$$

$$R_u(p) = R_u^{(1)}(p) + g_u \sum_{r \in \mathcal{M}_{exp}} \beta_r \bar{\rho}_r(u, p). \quad (29)$$

最终动态候选池为：

$$\mathcal{C}_u = \text{TopN}_{p \in \mathcal{C}_u^{(1)} \cup g_u \mathcal{C}_u^{(2)}} R_u(p). \quad (30)$$

从检索效率角度看, 若各来源访问成本为 c_r , 则单样本实际检索成本和高代价来源调用率为:

$$C_u^{retr} = \sum_{r \in \mathcal{M}_{cheap}} c_r + g_u \sum_{r \in \mathcal{M}_{exp}} c_r, \quad (31)$$

$$\text{ExpandRate} = \frac{1}{|\mathcal{D}|} \sum_{u \in \mathcal{D}} g_u. \quad (32)$$

因此, CACR 本质上是在候选覆盖率约束下进行自适应查询计划优化, 通过减少不必要的高代价索引访问降低平均在线检索开销。

3.4 用户画像条件化的时空序列建模

在获得历史 POI 的用户条件化融合表示后, 本文进一步建模用户短期轨迹演化。对于历史序列 $\mathcal{S}_u^{t-1} = [(p_1, t_1), \dots, (p_{t-1}, t_{t-1})]$, 首先得到融合表示序列:

$$\mathbf{H}_u^{t-1} = [\mathbf{h}_{u,p_1}, \mathbf{h}_{u,p_2}, \dots, \mathbf{h}_{u,p_{t-1}}]. \quad (33)$$

为显式刻画历史签到相对于当前轨迹末端的位置关系, 以末次兴趣点 p_{t-1} 为参照, 构造相对空间特征:

$$\delta_i^{spa} = [\text{lat}_{p_i} - \text{lat}_{p_{t-1}}, \text{lon}_{p_i} - \text{lon}_{p_{t-1}}, d_i], \quad (34)$$

其中 d_i 为 p_i 与 p_{t-1} 之间的欧氏距离。相对空间编码为:

$$\mathbf{r}_i^{spa} = \text{LN}(\text{MLP}_{rel}(\delta_i^{spa})). \quad (35)$$

同时, 将历史签到时间映射到星期-小时槽:

$$s_i = 24 \cdot \text{weekday}_i + \text{hour}_i, \quad \mathbf{e}_i^{time} = \mathbf{E}_{time}[s_i]. \quad (36)$$

由此得到时空增强签到表示:

$$\mathbf{x}_i = \mathbf{h}_{u,p_i} + \mathbf{r}_i^{spa} + \mathbf{e}_i^{time}. \quad (37)$$

用户画像不仅用于控制模态融合, 还作为条件前缀参与序列建模。条件化输入序列为:

$$\bar{\mathbf{X}}_u = [\mathbf{l}_u, \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{t-1}]. \quad (38)$$

本文采用带因果掩码的 Transformer 编码该序列:

$$\mathbf{Z}_u = \text{Transformer}_{causal}(\bar{\mathbf{X}}_u), \quad (39)$$

并选取最后一个有效历史签到位置的输出作为轨迹上下文状态 $\mathbf{z}_{t-1}$ 。由于序列首位为用户画像前缀, 实际索引相对原始签到序列偏移一位。为刻画用户下一次签到发生的目标时间条件, 本文进一步引入目标签到时间槽和时间间隔编码:

$$\tilde{\mathbf{z}}_{t-1} = \mathbf{z}_{t-1} + \mathbf{e}_t^{target} + \mathbf{e}_t^{gap}. \quad (40)$$

最终用户动态查询表示为:

$$\mathbf{q}_u = \text{LN}(\text{MLP}_{query}(\tilde{\mathbf{z}}_{t-1})). \quad (41)$$

需要指出的是, 用户画像已在 Transformer 输入端作为前缀参与建模, 因此不再在查询构建阶段与最终状态重复拼接。

3.5 候选重排序与模型优化

对于动态候选池 $\mathcal{C}_u$ 中的候选兴趣点 p , 本文同样通过三模态编码、跨模态交互和用户画像条件化融合得到候选表示, 并投影到与查询相同的隐空间:

$$\mathbf{v}_p = \text{Proj}_{cand}(\mathbf{h}_{u,p}). \quad (42)$$

对查询和候选向量进行 L_2 归一化后, 神经匹配分数定义为缩放余弦相似度:

$$s_{match}(u, p) = \gamma \bar{\mathbf{q}}_u^\top \bar{\mathbf{v}}_p, \quad \gamma = \exp(\omega), \quad (43)$$

其中 ω 为可学习缩放参数。

同时, 本文可构造候选上下文特征:

$$\mathbf{f}_{u,p}^{cand} = [d_{u,p}, a_{u,p}^{cat}, R_u(p), a_{u,p}^{src}], \quad (44)$$

其中 $d_{u,p}$ 表示候选与末次签到位置的距离, $a_{u,p}^{cat}$ 表示候选类别是否与末次签到类别一致, $a_{u,p}^{src}$ 表示候选是否至少由一个来源召回。其特征得分为:

$$s_{feat}(u, p) = \text{MLP}_{feat}(\mathbf{f}_{u,p}^{cand}). \quad (45)$$

完整候选得分可写为:

$$s(u, p) = s_{match}(u, p) + s_{feat}(u, p). \quad (46)$$

给定候选池内真实下一兴趣点索引 y , 排序损失采用候选集内交叉熵:

$$\mathcal{L}_{rank} = -\log \frac{\exp(s_y)}{\sum_{j=1}^{|\mathcal{C}_u|} \exp(s_j)}. \quad (47)$$

综合推荐排序目标和跨模态对齐目标, 模型总损失为:

$$\mathcal{L} = \mathcal{L}_{rank} + \lambda_{align} \mathcal{L}_{align}. \quad (48)$$

最终推荐结果为:

$$\mathcal{R}_u^K = \text{TopK}_{p \in \mathcal{C}_u} s(u, p). \quad (49)$$

4 实验与结果分析

4.1 实验设置

4.1.1 数据集

本文选取两个真实城市签到数据集进行实验, 包括纽约市签到数据集(NYC)和东京签到数据集(TKY)。两个数据集均来源于 Foursquare 平台公开签到数据^[25], 包含用户标识、兴趣点标识、类别信息、地理坐标以及时间戳等多模态城市轨迹信息, 可用于验证本文多模态融合方法的有效性。

实验采用与近期研究接近的评测协议^[26]。具体而言, 首先过滤低频兴趣点和低活跃用户, 以降低极端稀疏行为对模型训练的影响; 随后, 按照时间顺序组织每个用户的签到序列, 保留最近访问轨迹作为测试

样本, 并利用长度为 30 的历史序列作为模型输入。为保证评测过程的一致性, 本文在完成过滤和样本构造后统计数据集规模, 结果如表 1 所示。

表 1 整理后的数据集统计信息

数据集	用户数量	POI 数量	训练样本数量	测试样本数量
NYC	1,072	5,118	114,321	1,071
TKY	2,284	7,861	376,448	2,284

4.1.2 评价指标

本文采用下一兴趣点推荐任务中常用的评价指标, 包括 Hit Ratio (HR@K)、Normalized Discounted Cumulative Gain (NDCG@K) 以及 Mean Reciprocal Rank (MRR)。设测试集大小为 $|\mathcal{T}|$, 第 i 个测试样本的真实下一兴趣点排名为 $rank_i$, 则各指标定义如下。

Hit Ratio 用于衡量真实访问兴趣点是否出现在 Top- K 推荐列表中, 其计算公式为:

$$HR@K = \frac{1}{|\mathcal{T}|} \sum_{i=1}^{|\mathcal{T}|} \mathbb{I}(rank_i \leq K). \quad (50)$$

其中 $\mathbb{I}(\cdot)$ 为指示函数, 当条件成立时取 1, 否则取 0。

NDCG 用于同时考虑命中情况与推荐位置, 其计算公式为:

$$NDCG@K = \frac{1}{|\mathcal{T}|} \sum_{i=1}^{|\mathcal{T}|} \frac{\mathbb{I}(rank_i \leq K)}{\log_2(rank_i + 1)}. \quad (51)$$

MRR 用于衡量真实下一兴趣点在推荐结果中的平均倒数排名, 其计算公式为:

$$MRR = \frac{1}{|\mathcal{T}|} \sum_{i=1}^{|\mathcal{T}|} \frac{1}{rank_i}. \quad (52)$$

其中, 较高的 HR@K 表示模型具有更好的命中能力, 较高的 NDCG@K 表示模型能够将真实兴趣点排在更靠前的位置, 而较高的 MRR 则说明模型整体排序质量更优。

4.1.3 对比方法

为了全面验证本文方法的有效性, 本文选取了多种具有代表性的下一兴趣点推荐与序列推荐方法作为基线, 包括: SASRec^[12]、BERT4Rec^[13]、DuoRec^[27]、TiCoSeRec^[28]、CrossDR^[29]、MAERec^[30]、GETNext^[17]、POIGDE^[31]、DiffuRec^[32] 以及 LLM4POI^[33]。其中, SASRec 和 BERT4Rec 属于典型的序列推荐模型; GETNext 等方法能够结合时空依赖建模用户移动行为; LLM4POI 则进一步利用大语言模型的语义理解能力增强下一兴趣点推荐。相关对比结果主要参考近期研究在相近评测协议下报告的结果, 并结合本文整理后的数据设置进行对照分析。

4.1.4 实验实现

本文模型基于 PyTorch 实现。优化器采用 AdamW, 学习率设置为 3×10^{-4} , 权重衰减为 10^{-2} , 批次大小为 256, Dropout 为 0.1, 并采用梯度裁剪稳定训练过程。兴趣点隐空间维度设置为 128, 序列编码器采用 2 层 Transformer Encoder, 包含 4 个注意力头, 并使用因果掩码保证历史信息约束。最大历史长度设置为 30, 候选池大小设置为 256, 推荐损失采用候选集内交叉熵损失, 负例由候选池中除真实目标外的兴趣点构成; 当真实目标未被候选池覆盖时, 该样本不计算排序损失。拓扑表示中的 Node2Vec 维度为 64, 游

走长度为 10，每节点游走次数为 5，参数 p 和 q 均设置为 1.0；文本语义特征采用 TF-IDF 结合 Truncated SVD 得到 64 维表示。Alignment Loss 权重设置为 0.01。所有实验在固定随机种子下运行，报告平均结果。

4.2 整体性能分析

首先，本文在 NYC 和 TKY 两个数据集上将所提方法与已有基线方法进行整体比较，结果如表 2 所示。实验结果表明，本文方法能够有效利用城市轨迹中的多模态信息，在用户历史行为基础上进一步融合兴趣点语义、拓扑关系和空间约束，从而提升下一访问位置预测能力。与 SASRec、BERT4Rec、DuoRec 等序列推荐模型相比，本文方法在 NYC 和 TKY 两个数据集上的大多数指标上取得了较为明显的提升，说明仅依赖行为序列难以充分刻画城市轨迹中的复杂影响因素，而融合兴趣点语义、拓扑关系与空间信息后，模型能够学习到更具判别性的兴趣表示。进一步地，与 GETNext 等结合时空建模能力的方法相比，本文方法仍取得了更优结果，说明在显式建模时空依赖的基础上，进一步引入多模态信息及其融合机制能够持续增强推荐性能。需要指出的是，在 NYC 数据集上，LLM4POI 在 MRR 指标上略高于本文方法，这表明基于大语言模型的语义增强策略在个别排序位置上具有一定优势；但从 HR@10 和 NDCG@10 来看，本文方法仍表现更优，说明其在候选命中能力和整体排序质量方面具有更稳定的综合性能。这表明，城市轨迹推荐不仅依赖访问顺序和时空连续性，还受兴趣点功能语义与结构转移关系的共同影响，本文提出的多模态融合框架能够较好地刻画这类复杂关联。

表 2 NYC 和 TKY 数据集与已有方法比较

Method	NYC			TKY		
	HR@10	NDCG@10	MRR	HR@10	NDCG@10	MRR
SASRec	0.4828	0.3126	0.2701	0.4325	0.2837	0.2470
BERT4Rec	0.4670	0.3094	0.2711	0.4347	0.2908	0.2539
DuoRec	0.4069	0.2634	0.2276	0.3119	0.2089	0.1867
TiCoSeRec	0.4808	0.3204	0.2754	0.3704	0.2421	0.2151
CrossDR	0.4720	0.3259	0.2866	0.4057	0.2619	0.2265
MAERec	0.4453	0.2985	0.2610	0.4066	0.2614	0.2305
GETNext	0.5130	0.3513	0.3097	0.4850	0.3321	0.2921
POIGDE	0.3836	0.2797	0.2540	0.3182	0.2357	0.2180
DiffuRec	0.4079	0.3023	0.2774	0.3989	0.2870	0.2594
LLM4POI	0.4666	0.3816	0.3590	0.3948	0.2822	0.2972
Ours	0.5257	0.3828	0.3442	0.5346	0.3574	0.3110

此外，从两个数据集的结果来看，NYC 上的 NDCG@10 和 MRR 相对更高，说明模型在该数据集上能够取得更优的排序质量；而 TKY 上的 HR@10 略高，说明本文方法在更大规模城市轨迹场景下仍能保持较好的候选命中能力。这说明，本文提出的多模态轨迹数据融合框架具有较好的跨数据集适应性。

4.3 模态贡献消融分析

为了分析不同模态信息对于推荐任务的贡献，本文进一步设计模态消融实验，结果如表 3 所示。完整模型在 HR@10、NDCG@10 和 MRR 上分别达到 0.5257、0.3828 和 0.3442。去除任一模态后，三项指标均出现下降，说明语义、拓扑和空间信息均能够为下一兴趣点预测提供有效增益，且其作用同时体现在候选命中能力和排序质量两个方面。其中，拓扑模态对 HR@10 和 NDCG@10 的影响更为显著，语义模态对 MRR 的贡献相对更突出，空间模态则从地理约束角度提供稳定补充，三者共同提升了兴趣点表示的判别能力。

具体而言，去除拓扑模态后，HR@10、NDCG@10 和 MRR 分别下降至 0.5117、0.3766 和 0.3414，在三种单模态消融中表现出最明显的 HR@10 和 NDCG@10 下降。该结果表明，由用户历史轨迹构建的 POI

表 3 不同模态消融实验

Variant (NYC)	HR@10	NDCG@10	MRR
Full Model	0.5257	0.3828	0.3442
w/o Topology	0.5117	0.3766	0.3414
w/o Semantic	0.5244	0.3815	0.3409
w/o Spatial	0.5210	0.3812	0.3435

转移关系能够提供关键的结构化行为先验, 帮助模型更好地刻画城市活动中的转移规律与行为关联, 从而提升候选命中能力和前列排序质量。

去除语义模态后, 模型性能降至 0.5244、0.3815 和 0.3409, 其中 MRR 降幅在三种模态中相对更大, 说明兴趣点类别和文本语义能够有效刻画 POI 的功能属性, 并有助于模型更准确地识别用户访问意图。相比单纯依赖历史访问关系, 语义信息能够缓解行为数据稀疏和转移模式不充分带来的影响, 因此对精细排序具有稳定贡献。

去除空间模态后, 模型性能下降至 0.5210、0.3812 和 0.3435, 表明地理空间约束同样对下一兴趣点推荐具有积极作用。空间信息能够刻画用户活动范围和局部移动偏好, 有助于模型在候选排序过程中考虑地理可达性。虽然其降幅相对较小, 但仍说明空间模态对最终性能具有稳定的正向贡献。

4.4 跨模态融合模块消融分析

为了验证本文提出的跨模态交互机制和自适应融合机制的有效性, 本文进一步进行了模块消融实验。由表 4 可见, 跨模态交互和自适应门控分别从关联建模和动态融合两个方面提升模型性能。其中, 跨模态交互的作用更为显著, 自适应门控也提供了稳定的正向增益。上述结果说明, 本文方法的优势不仅来自多模态信息输入, 更依赖于对多模态信息之间关系及其融合过程的有效建模。

表 4 跨模态模块消融实验

Variant (NYC)	HR@10	NDCG@10	MRR
Full Model	0.5257	0.3828	0.3442
w/o Cross-modal Interaction	0.5154	0.3726	0.3340
w/o Adaptive Gate	0.5202	0.3798	0.3435

具体而言, 去除跨模态交互后, HR@10、NDCG@10 和 MRR 分别下降至 0.5154、0.3726 和 0.3340, 在三种模块消融中降幅最大, 说明不同模态之间的显式信息交互是提升融合表示质量的关键因素。若缺少该模块, 各模态主要以独立表示形式参与融合, 难以充分建模语义、拓扑和空间信息之间的潜在关联。去除自适应门控后, 模型性能下降至 0.5202、0.3798 和 0.3435。该结果表明, 固定融合策略难以适应不同用户状态和轨迹上下文下的模态重要性差异, 而上下文感知的门控机制能够动态调整各模态贡献, 从而提升模型在不同场景下的融合效果。

为了进一步解释自适应融合模块的工作机制, 本文统计了 NYC 数据集上不同上下文场景下三类模态的平均门控权重分布, 如图 3 所示。可以看到, 拓扑模态在所有场景中均占主导地位, 其平均门控权重稳定保持在 0.7449~0.7942 之间, 说明 NYC 数据集的下一兴趣点预测整体上仍然高度依赖历史转移结构信息。与此同时, 左图中的绝对值范围虽然揭示了模态主次关系, 但同一模态在不同场景下的数值变化较小, 仅凭单一色标不易直接辨识, 因此本文在右图进一步给出了相对各模态全局均值的场景偏移, 以更清晰地呈现场景差异。

结合两幅子图可以进一步发现, 短距离转移场景下空间模态权重最高, 达到 0.1765, 且相对全局均值呈现最明显的正偏移; 对应地, 拓扑模态在该场景下降至 0.7449, 为所有场景中的最低值。这表明当用户




图 3 NYC 数据集上不同上下文场景下的门控权重分布。左图给出三类模态在各场景下的绝对平均门控权重, 右图给出相对各模态全局均值的场景偏移, 用于突出细粒度变化。

发生近距离迁移时, 地理邻近性更容易被门控机制激活, 而模型对拓扑先验的依赖相对减弱。相反, 在长距离转移场景下, 拓扑模态权重回升至 0.7907, 空间模态降至 0.1416, 说明跨区域移动时模型更倾向于依赖较稳定的结构转移关系, 而非单纯的空间邻近约束。

此外, 语义模态的绝对权重整体较低, 全局均值仅为 0.0683, 但在工作日夜间和短距离转移场景中分别上升至 0.0741 和 0.0786, 均高于其全局平均水平。这说明尽管语义信息不是主导因素, 但在部分更具行为歧义或探索性的场景下, 地点功能属性仍能提供额外判别线索。总体而言, 该结果说明自适应门控并非对多模态特征做静态平均, 而是能够在保持拓扑主导结构的同时, 对语义和空间信息进行与场景相关的动态重加权, 从而提升模型的场景适应能力与可解释性。

4.5 代价感知候选池构建分析

为了进一步验证代价感知候选池构建模块的工程收益, 本文在 NYC 数据集上固定已训练完成的模型参数, 仅替换候选池构建策略进行对比分析。当前仅保留三种代表性策略: CACR、固定和随机。其中, CACR 表示本文方法中的代价感知自适应级联检索策略, 其首先访问低代价候选来源, 再根据第一阶段候选规模与分布不确定性决定是否访问高代价候选来源; 固定方法则在相同的 $candidate_k = 128$ 约束下, 对每个查询均访问全部候选来源, 即无论第一阶段候选是否已经充分, 都固定执行高代价候选扩展, 因此其高代价调用率始终为 100%; 随机方法则以与 CACR 相近的扩展概率随机决定是否访问高代价候选来源, 用作对照组, 以区分“代价感知决策”与“随机减少调用”所带来的差异。

如图 4(a) 所示, CACR 在候选召回仅小幅下降的情况下显著降低了检索开销。与固定方法相比, CACR 的候选召回率 $Recall@128$ 由 0.7003 下降到 0.6956, 损失约 0.0047; 但平均检索延迟由 3.4727ms 下降到 2.9278ms, 降幅约 15.69%, 说明基于中间结果的自适应扩展能够有效减少不必要的高代价访问, 同时保持较强的候选覆盖能力。相比之下, 随机方法虽然与 CACR 具有接近的高代价扩展率, 但其召回率进一步下降到 0.6928, 平均检索延迟也高于 CACR, 说明简单的随机跳过并不能得到同样稳定的效率-效果折中。

从图 4(b) 可以进一步看出, CACR 带来的检索加速并未破坏最终推荐质量。以 CACR 为基准时, 固定方法的 $\Delta HR@10$ 和 $\Delta NDCG@10$ 分别为 -0.0019 和 -0.0002, 变化幅度很小, 说明额外访问全部高代价来源并未显著改善最终排序结果; 随机方法的 $\Delta HR@10$ 和 $\Delta NDCG@10$ 则分别下降到 -0.0047 和 -0.0077, 退化更加明显。这表明, 在当前多模态精排框架中, 当第一阶段候选已经具备较好覆盖率时, 基于候选规模与分布不确定性的自适应扩展更有利于在较低代价下保持稳定效果, 而随机减少高代价访问则会带来更明显的质量损失。




图 4 NYC 数据集上代价感知候选池构建的效率-效果分析结果。(a) 给出候选召回与平均检索延迟之间的折中关系；(b) 给出各策略相对 CACR 的最终推荐性能变化；(c) 给出高代价候选源调用率与绝对 QPS。

图 4(c) 则直接展示了代价感知策略的系统收益。固定方法对全部查询均执行高代价候选扩展，因此其高代价候选源调用率为 100%，对应 QPS 为 287.96；CACR 将高代价候选源调用率降至 68.25%，同时 QPS 提升至 341.55，吞吐增幅约 18.61%。值得注意的是，随机方法与 CACR 具有接近的高代价调用率，但其 QPS 仅为 312.00，且 HR@10、NDCG@10 分别低于 CACR 0.0047 和 0.0077。这说明系统收益并非来自对高代价访问的随机削减，而是来自依据第一阶段候选结果进行决策的代价感知自适应查询计划。综合而言，代价感知候选池构建在不重新训练模型的前提下，就能够为下一兴趣点推荐带来可观的效率收益，并保持稳定的最终推荐性能。

4.6 参数敏感性分析

为了进一步验证关键超参数设置的合理性，本文在 NYC 数据集上补充开展参数敏感性分析，分别考察跨模态一致性损失权重 λ 和历史序列长度 L 对模型性能的影响。考虑到两组实验均用于说明模型对训练与输入配置的鲁棒性，本文将其汇总展示为同一图中的两个子图，如图 5 所示。




图 5 NYC 数据集上跨模态对齐损失权重 λ 与历史序列长度 L 的参数敏感性分析结果。图中曲线表示以默认配置归一化后的 HR@10、NDCG@10 和 MRR 变化趋势，点旁数字表示对应的绝对指标值。

从图 5(a) 可以看出, 当 λ 取 0.005、0.01 和 0.05 时, HR@10、NDCG@10 和 MRR 整体仅呈现轻微波动。例如, HR@10 分别为 0.5265、0.5257 和 0.5283, NDCG@10 分别为 0.3831、0.3828 和 0.3841, MRR 分别为 0.3441、0.3442 和 0.3449。该结果说明, 在较小到中等的对齐损失权重范围内, 模型对 λ 的变化并不敏感, 表现出一定鲁棒性。其中 $\lambda = 0.05$ 在本组实验中略优, 但整体差异有限, 因此主实验采用的 $\lambda = 0.01$ 仍可视作处于性能稳定区间的合理设置。

从图 5(b) 可以看出, 历史序列长度对模型性能的影响比 λ 更为明显。当 $L = 10$ 时, HR@10、NDCG@10 和 MRR 分别为 0.5177、0.3781 和 0.3405, 均低于其余设置; 当长度增加到 20 时, 三项指标同步提升, 其中 NDCG@10 和 MRR 分别达到 0.3842 和 0.3460。继续增大到 30 和 50 后, 性能仅小幅波动, 其中 $L = 30$ 对应 HR@10、NDCG@10 和 MRR 分别为 0.5257、0.3828 和 0.3442, $L = 50$ 分别为 0.5274、0.3837 和 0.3446。该结果表明, 当历史上下文达到一定规模后, 更长序列带来的边际收益已经有限。结合训练耗时观察, $L = 50$ 会带来更高的训练成本而未显著提升效果, 因此主实验采用的 $L = 30$ 可视为性能与效率之间的稳妥折中, 而 $L = 20 \sim 30$ 则是较为合理的取值区间。

5 结论与展望

随着智慧城市和位置服务应用的快速发展, 城市轨迹数据在语义属性、空间分布、拓扑转移和行为上下文等方面呈现出显著的多模态特征。下一兴趣点推荐需要在动态用户状态和大规模候选空间下综合利用上述信息, 因此不仅要求模型能够学习不同模态的有效表示, 还需要进一步刻画模态之间的互补关系, 并在候选生成阶段兼顾推荐质量与在线效率。针对现有方法在多模态统一建模、动态融合以及候选检索代价控制方面的不足, 本文提出了面向下一兴趣点推荐的跨模态自适应融合与检索方法 CAFR。

具体而言, 本文首先从兴趣点语义、访问拓扑和空间位置三个角度构建多模态表示, 并通过跨模态交互机制与一致性约束增强不同模态之间的信息传递和表示对齐能力, 从而缓解异构轨迹信息独立编码所带来的信息割裂问题。其次, 本文设计了上下文感知的自适应融合机制, 利用用户偏好、时间上下文和当前轨迹状态动态生成模态权重, 使模型能够根据不同移动场景调整语义、拓扑和空间信息的贡献。进一步地, 本文从检索效率角度提出代价感知的自适应级联多索引检索策略, 优先访问低代价候选来源, 并根据第一阶段候选充分性与不确定性按需扩展高代价索引, 从而在候选覆盖率和在线检索开销之间取得平衡。最后, 本文将融合后的兴趣点表示与序列建模相结合, 实现候选池约束下的下一兴趣点预测与排序。

在纽约和东京两个真实城市签到数据集上的实验结果表明, CAFR 能够有效利用多模态城市轨迹信息, 在 HR@10、NDCG@10 和 MRR 等指标上整体优于多种代表性序列推荐、时空推荐和语义增强方法。模态消融实验表明, 语义、拓扑和空间信息均能够为下一兴趣点预测提供有效增益, 其中拓扑关系有助于提升候选命中能力, 语义信息有助于改善精细排序, 空间信息则提供了稳定的地理约束补充。模块消融实验进一步验证了跨模态交互和自适应门控机制的有效性, 说明本文方法的性能提升不仅来自多模态信息输入, 更来自对模态关联和场景依赖融合过程的显式建模。此外, 代价感知候选池构建实验表明, CAFR 能够在保持最终推荐性能基本稳定的同时降低高代价候选源调用率并提升系统吞吐, 体现了其在大规模 POI 推荐场景中的潜在部署价值。

未来工作可从以下方面展开。首先, 研究更灵活的候选生成与增量召回机制, 提升模型对长尾兴趣点、新增兴趣点和冷启动用户的适应能力。其次, 当前方法主要利用类别文本、转移关系和地理坐标等信息, 未来可引入道路网络、实时交通、用户评论、图像内容和城市知识图谱等外部信息, 构建粒度更细、语义更强的城市多模态表示。再次, 随着大规模语言模型和多模态基础模型的发展, 如何将轨迹序列、空间路径和兴趣点语义与基础模型有效对齐, 并在保证可解释性和可控性的前提下增强轨迹理解能力, 仍值得深入研究。最后, 真实在线应用中还需考虑动态索引更新、延迟约束、隐私保护和跨城市泛化等问题, 推动多模态城市轨迹推荐方法从离线实验走向更稳健可信的实际部署。

References

- [1] Y. Zheng et al. “Urban Computing: Concepts, Methodologies, and Applications”. In: *ACM Transactions on Intelligent Systems and Technology* 5.3 (2014), 38:1–38:55. doi: 10.1145/2629592.
- [2] S. Wang, J. Cao, and P. S. Yu. “Deep Learning for Spatio-Temporal Data Mining: A Survey”. In: *IEEE Transactions on Knowledge and Data Engineering* 34.8 (2022), pp. 3681–3700. doi: 10.1109/TKDE.2020.3025580.
- [3] T. Baltrušaitis, C. Ahuja, and L.-P. Morency. “Multimodal Machine Learning: A Survey and Taxonomy”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41.2 (2019), pp. 423–443. doi: 10.1109/TPAMI.2018.2798607.
- [4] J. Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. 2019, pp. 4171–4186. doi: 10.18653/v1/N19-1423.
- [5] A. Grover and J. Leskovec. “node2vec: Scalable Feature Learning for Networks”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 855–864. doi: 10.1145/2939672.2939754.
- [6] A. Radford et al. “Learning Transferable Visual Models from Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning*. 2021, pp. 8748–8763. URL: <https://proceedings.mlr.press/v139/radford21a.html>.
- [7] Y. Zheng. “Trajectory Data Mining: An Overview”. In: *ACM Transactions on Intelligent Systems and Technology* 6.3 (2015), pp. 1–41. doi: 10.1145/2743025.
- [8] P. Sánchez and A. Bellogín. “Point-of-Interest Recommender Systems Based on Location-Based Social Networks: A Survey from an Experimental Perspective”. In: *ACM Computing Surveys* 54.11s (2022), pp. 1–37. doi: 10.1145/3510409.
- [9] J. Tang et al. “A Survey of Studies on Deep Learning Applications in POI Recommendation”. In: *Computer Engineering* 48.1 (2022), pp. 12–23, 42. doi: 10.19678/j.issn.1000-3428.0061598. (in Chinese with English abstract).
- [10] G. Liu, F. Wang, and Z. Wu. “Survey on Next Point-of-Interest Recommendation Algorithms”. In: *Journal of Frontiers of Computer Science and Technology* 19.7 (2025), pp. 1747–1770. doi: 10.3778/j.issn.1673-9418.2408046. (in Chinese with English abstract).
- [11] Q. Yuan et al. “Time-Aware Point-of-Interest Recommendation”. In: *Proceedings of the 36th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2013, pp. 363–372. doi: 10.1145/2484028.2484030.
- [12] W.-C. Kang and J. McAuley. “Self-Attentive Sequential Recommendation”. In: *Proceedings of the IEEE International Conference on Data Mining (ICDM)*. 2018, pp. 197–206. doi: 10.1109/ICDM.2018.00035.
- [13] F. Sun et al. “BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer”. In: *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*. 2019, pp. 1441–1450. doi: 10.1145/3357384.3357895.
- [14] L. Huang et al. “An Attention-Based Spatiotemporal LSTM Network for Next POI Recommendation”. In: *IEEE Transactions on Services Computing* 14.6 (2019), pp. 1585–1597. doi: 10.1109/TSC.2018.2871669.
- [15] P. Zhao et al. “Where to Go Next: A Spatio-Temporal Gated Network for Next POI Recommendation”. In: *IEEE Transactions on Knowledge and Data Engineering* 34.5 (2022), pp. 2512–2524. doi: 10.1109/TKDE.2020.3007194.
- [16] Y. Luo, Q. Liu, and Z. Liu. “STAN: Spatio-Temporal Attention Network for Next Location Recommendation”. In: *Proceedings of the ACM Web Conference*. 2021, pp. 2177–2185. doi: 10.1145/3442381.3449998.
- [17] S. Yang, J. Liu, and K. Zhao. “GETNext: Trajectory Flow Map Enhanced Transformer for Next POI Recommendation”. In: *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2022, pp. 1144–1153. doi: 10.1145/3477495.3531983.
- [18] X. Wang et al. “Modeling Spatio-temporal Neighbourhood for Personalized Point-of-Interest Recommendation”. In: *Proceedings of the 31st International Joint Conference on Artificial Intelligence (IJCAI)*. 2022, pp. 3530–3536. doi: 10.24963/ijcai.2022/490.
- [19] X. Yan et al. “Spatio-Temporal Hypergraph Learning for Next POI Recommendation”. In: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2023, pp. 403–412. doi: 10.1145/3539618.3591770.
- [20] B. Chang et al. “Content-Aware Hierarchical Point-of-Interest Embedding Model for Successive POI Recommendation”. In: *Proceedings of the 27th International Joint Conference on Artificial Intelligence*. 2018, pp. 3301–3307. doi: 10.24963/ijcai.2018/458.
- [21] Y. Chen et al. “Robust Road Network Representation Learning: When Traffic Patterns Meet Traveling Semantics”. In: *Proceedings of the 30th ACM International Conference on Information and Knowledge Management*. 2021, pp. 211–220. doi: 10.1145/3459637.3482293.
- [22] M. Shi et al. “Next Point-of-Interest Recommendation Approach with Global and Local Feature Fusion”. In: *Journal of Software* 34.2 (2023), pp. 786–801. URL: <http://www.jos.org.cn/1000-9825/6712.htm>. (in Chinese with English abstract).

- [23] Z. Wang et al. “DSDRec: Next POI Recommendation Using Deep Semantic Extraction and Diffusion Model”. In: *Information Sciences* 678 (2024), p. 121004. DOI: 10.1016/j.ins.2024.121004.
- [24] J. Zeng et al. “Global and Local Hypergraph Learning Method with Semantic Enhancement for POI Recommendation”. In: *Information Processing & Management* 62.1 (2025), p. 103868. DOI: 10.1016/j.ipm.2024.103868.
- [25] D. Yang et al. “Modeling User Activity Preference by Leveraging User Spatial Temporal Characteristics in LBSNs”. In: *IEEE Transactions on Systems, Man, and Cybernetics: Systems* 45.1 (2015), pp. 129–142. DOI: 10.1109/TSMC.2014.2327053.
- [26] L. Zhong et al. “CoMaPOI: A Collaborative Multi-Agent Framework for Next POI Prediction Bridging the Gap Between Trajectory and Language”. In: *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval*. Padua, Italy, 2025. DOI: 10.1145/3726302.3729930.
- [27] R. Qiu et al. “Contrastive Learning for Representation Degeneration Problem in Sequential Recommendation”. In: *Proceedings of the 15th ACM International Conference on Web Search and Data Mining*. 2022, pp. 813–823. DOI: 10.1145/3488560.3498433.
- [28] Y. Dang et al. “Uniform Sequence Better: Time Interval Aware Data Augmentation for Sequential Recommendation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 2023, pp. 4225–4232.
- [29] Y. Shi et al. “Cross-domain Representation Disentanglement for Sequential Recommendation”. In: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2023.
- [30] Y. Ye, L. Xia, and C. Huang. “Graph Masked Autoencoder for Sequential Recommendation”. In: *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2023, pp. 321–330.
- [31] Y. Yang et al. “Siamese Learning Based on Graph Differential Equation for Next-POI Recommendation”. In: *Applied Soft Computing* 150 (2024), p. 111086. DOI: 10.1016/j.asoc.2023.111086.
- [32] W. Wang et al. “DiffuRec: A Diffusion Model for Sequential Recommendation”. In: *ACM Transactions on Information Systems*. Vol. 42. 2. 2023.
- [33] P. Li et al. “Large Language Models for Next Point-of-Interest Recommendation”. In: *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2024. DOI: 10.1145/3626772.3657840.

附中文参考文献

- [9] 汤佳欣, 陈阳, 周孟莹, 王新. 深度学习方法在兴趣点推荐中的应用研究综述. *计算机工程*, 2022, 48(1): 12–23, 42.
- [10] 刘广腾, 王峰, 吴中博. 下一个兴趣点推荐算法综述. *计算机科学与探索*, 2025, 19(7): 1747–1770.
- [22] 石美惠, 申德荣, 寇月, 聂铁铮, 于戈. 融合全局和局部特征的下一个兴趣点推荐方法. *软件学报*, 2023, 34(2): 786–801.

作者简介

高宇岑, 副教授, 硕士生导师, 主要研究领域为数据工程与优化算法。

王雪凝, 博士研究生, 主要研究领域为时空数据管理与智能推荐。

庄新鱼, 硕士研究生, 主要研究领域为大语言模型与强化学习。

王 斌, 博士, 教授, 博士生导师, CCF 专业会员, 主要研究领域为大数据管理与知识工程、分布式数据管理和社交网络分析。

杨晓春, 博士, 教授, 博士生导师, CCF 杰出会员, 主要研究领域包括大数据管理与知识工程、数据库理论与技术等。